UNIBALSAS Centro Universitário

SISTEMAS DE INFORMAÇÃO

CENTRO UNIVERSITÁRIO UNIBALSAS

BACHAREL EM SISTEMAS DE INFORMAÇÃO E TECNOLOGIA

Elias Chaves Sousa

Marcos Antonio Cirqueira

Kauan Leite Dos Santos

Pedro Vitor Rocha Do Val

TEDs 1, 2 e 3: Seleção, Preparação, Análise e Modelagem de Dados

Documento Técnico do Projeto JuriPredict, Versão 3.0

PROFESSOR: ALEX ROGALESKI MARQUES

BALSAS - MA

2026

HISTÓRICO DE VERSÕES

Versão	Data	Etapa	Alterações
3.0	Nov/2026	TEDs 1, 2 e 3	Versão consolidada. Substitui o conjunto de dados próprio pela base Brazilian Legal Proceedings e reúne em um só documento a seleção da base (seções 3 a 5), a limpeza e a análise exploratória (seções 6 e 7) e a modelagem (seções 8 a 10).

SUMÁRIO

1 IDENTIFICAÇÃO DA EQUIPE 5
2 ORGANIZAÇÃO DO DOCUMENTO 5
3 PROBLEMA DO PROJETO E SOLUÇÃO PROPOSTA 6
3.1 Problema 6
3.2 Solução proposta e relação com o MVP 6
3.3 Revisão da estratégia de dados 7
4 NECESSIDADES DE DADOS DA SOLUÇÃO 7
5 ALTERNATIVAS AVALIADAS E BASE SELECIONADA 8
5.1 Comparação entre alternativas 8
5.2 Identificação da base selecionada 9
5.3 Estrutura e principais atributos 9
5.4 Justificativa da escolha e relação com o problema 10
5.5 Limitações iniciais 10
6 LIMPEZA E PREPARAÇÃO DOS DADOS 11
6.1 Processo de limpeza 11
6.2 Problemas de qualidade e tratamentos 12
6.3 Base após o tratamento 13
7 ANÁLISE EXPLORATÓRIA 14
7.1 Estatísticas descritivas 14
7.2 Distribuição das classes e origem dos processos 14
7.3 Tamanho do histórico 15
7.4 Dimensão temporal 16
7.5 Conteúdo da última movimentação 17

7.6 Termos que distinguem as classes 18

7.7 Relações entre variáveis e base sem rótulo 18

7.8 Síntese da análise e consequências para o projeto 19

8 MODELAGEM 20

8.1 Definição do problema de aprendizado 20

8.2 Abordagem e justificativa 20

8.3 Preparação dos dados e seleção de variáveis 20

8.4 Divisão dos dados e protocolo de avaliação 21

8.5 Métricas 21

8.6 Linhas de base e experimentos 21

8.7 Resultados no conjunto de teste 24

8.8 Variáveis relevantes 25

8.9 Confiança e abstenção 26

8.10 Generalização entre tribunais e períodos 27

8.11 Sobreajuste e curva de aprendizado 28

8.12 Comparação com o estudo de referência 28

9 DISCUSSÃO DOS RESULTADOS 29

9.1 Contribuição do modelo para o problema 29

9.2 Limitações 29

9.3 Relação com o MVP e próximos passos 30

10 REGISTRO DE DECISÕES E MUDANÇAS DE ABORDAGEM 30

11 REPOSITÓRIO, DADOS E REPRODUÇÃO 32

REFERÊNCIAS 34

1 IDENTIFICAÇÃO DA EQUIPE

Nome completo	Matrícula	Papel no projeto
Elias Chaves Sousa	23.1.82553	ENGENHARIA DE DADOS E IA
Marcos Antonio Cirqueira	[PREENCHER]	DESENVOLVEDOR FRONT-END
Kauan Leite Dos Santos	23.1.80904	ENGENHARIA DE DADOS
Pedro Vitor Rocha Do Val	23.1.81712	DESENVOLVEDOR BACK-END

Unidade curricular: BIG DATA E CIÊNCIA DE DADOS, Período: 2026.2. Professor orientador: ALEX ROGALESKI MARQUES.

2 ORGANIZAÇÃO DO DOCUMENTO

Este documento reúne as três etapas de dados da unidade curricular. As seções 3 a 5 tratam da seleção da base (TED 01); as seções 6 e 7, da limpeza, da preparação e da análise exploratória (TED 02); as seções 8 a 10, da modelagem e da avaliação (TED 03). A seção 11 descreve o repositório e o procedimento para reproduzir os resultados.

O planejamento anterior previa a construção de um conjunto próprio de sentenças trabalhistas. Esse caminho foi interrompido, e a seção 3.3 registra os motivos e o que mudou no problema tratado. Todos os números citados foram produzidos pelos scripts do repositório e ficam gravados em arquivos da pasta *resultados/*, de modo que cada valor do texto pode ser conferido na origem.

3 PROBLEMA DO PROJETO E SOLUÇÃO PROPOSTA

3.1 Problema

O JuriPredict é voltado ao advogado autônomo e à pequena banca, com atuação inicial em Balsas e no sul do Maranhão. A plataforma reúne a gestão da carteira de processos e, como objetivo de longo prazo, a jurimetria: estimar, por unidade julgadora, como determinado tipo de pedido costuma ser decidido. O planejamento de dados original atendia apenas a esse segundo objetivo e dependia de um conjunto de sentenças rotuladas que não chegou a ser concluído.

O problema tratado nesta etapa é anterior à jurimetria e aparece na rotina de qualquer escritório: saber em que situação está cada processo da carteira. A informação existe nas movimentações registradas pelos tribunais, mas chega como uma sequência de textos curtos, escritos na linguagem de cada sistema e sem padronização entre tribunais. Para concluir se um processo foi arquivado em definitivo, se está suspenso à espera de alguma providência ou se segue tramitando, o advogado precisa ler as últimas movimentações e interpretá-las. Com dezenas de processos, essa leitura acontece de forma esparsa, e a situação anotada no sistema do escritório fica desatualizada.

No MVP, a desatualização tem efeito direto. A entidade Processo guarda a situação em três valores (ATIVO, SUSPENSO e ARQUIVADO), preenchidos pelo usuário, e a rotina que busca novos andamentos na API pública do DataJud percorre somente os processos marcados como ATIVO. Um processo marcado como arquivado por engano deixa de ser acompanhado, e um prazo aberto nele passa despercebido. No sentido oposto, um processo já encerrado que continua marcado como ativo ocupa a atenção do advogado sem necessidade.

3.2 Solução proposta e relação com o MVP

A solução é um classificador que lê as movimentações mais recentes de um processo e sugere uma das três situações, acompanhada de uma probabilidade. A sugestão não substitui o registro feito pelo advogado: quando a probabilidade fica abaixo de um limiar, o sistema não sugere nada e indica que o caso precisa de leitura. A regra segue o compromisso já assumido pelo projeto de não exibir números que os dados não sustentam.

No MVP, o classificador entraria na etapa de sincronização de andamentos. Ao receber movimentações novas, o sistema compararia a situação sugerida com a registrada e sinalizaria as divergências para conferência, sem alterar o cadastro sozinho. Nesta entrega, o modelo foi treinado e avaliado fora da aplicação. A integração com o back-end não foi feita, e a seção 9 explica em que condições ela passa a fazer sentido.

3.3 Revisão da estratégia de dados

O planejamento inicial previa um conjunto próprio, formado por sentenças do TRT da 16ª Região obtidas no sistema FALCÃO e por metadados da API pública do DataJud. A coleta reuniu 787 sentenças publicadas entre janeiro de 2024 e janeiro de 2026, que deram origem a 618 linhas de pedido e a 413 casos na população destinada ao modelo, distribuídos por 22 varas. Três problemas impediram o uso desse material.

O primeiro foi o tamanho. Com 413 casos e taxa de deferimento de 67,3%, uma divisão temporal deixaria cerca de cem casos para teste, e o intervalo de confiança de qualquer ganho sobre a linha de base incluiria o zero. A própria equipe havia fixado entre 3.000 e 5.000 casos como patamar para sustentar uma afirmação preditiva.

O segundo foi a qualidade do rótulo. Cerca de 89% dos rótulos vinham de regras de texto e 11% da leitura automática por modelo de linguagem. A amostra de conferência humana, com 70 casos sorteados, foi preparada, mas nenhum caso chegou a ser anotado. Sem essa medição não há como saber se o erro de rotulagem varia com o desfecho, que é justamente o tipo de erro capaz de distorcer uma taxa de deferimento.

O terceiro foi a cobertura. O assunto 13875 da tabela processual do CNJ, usado para localizar as ações sobre adicional de insalubridade, aparecia em apenas 45% das sentenças que de fato julgavam o tema, o que deixava incerto o denominador das taxas.

Diante disso, a equipe decidiu trocar a base e, com ela, o problema de aprendizado. O conjunto próprio permanece no repositório, nas pastas *dataset/* e *publicacao/*, como registro histórico, e não é usado em nenhuma análise deste documento.

4 NECESSIDADES DE DADOS DA SOLUÇÃO

A partir do problema da seção 3, a equipe listou o que a base precisa oferecer antes de comparar as alternativas. A Tabela 1 registra cada necessidade, o motivo e o quanto a base selecionada atende.

Tabela 1 - Necessidades de dados e atendimento pela base selecionada

Código	Necessidade	Motivo	Atendimento
N1	Movimentações processuais em texto, em ordem, por processo	É a informação que o advogado lê para concluir a situação	Sim. De 1 a 2.659 movimentações por processo, da mais recente para a mais antiga
N2	Rótulo de situação atribuído por pessoa com formação jurídica	Treino e avaliação supervisionados	Sim. 6.449 processos rotulados por advogados
N3	Volume que permita separar teste e estimar incerteza	Evitar a limitação do conjunto próprio	Sim. Cerca de quinze vezes os 413 casos do conjunto anterior
N4	Classes compatíveis com o MVP	Usar a sugestão sem conversão de categorias	Sim. Arquivado, ativo e suspenso, os mesmos três valores do cadastro
N5	Acesso público e reprodutível	Permitir a conferência dos resultados	Sim, com ressalva. Download público sem credencial; licença declarada como "Unknown"
N6	Data de cada movimentação	Avaliação com divisão temporal	Parcial. Não há campo de data; o ano foi inferido do texto (seção 6)
N7	Mesmo ramo de justiça do MVP	Aplicar o modelo sem adaptação	Não. A base é da justiça estadual de São Paulo e do Rio de Janeiro

Fonte: elaborado pela equipe (2026).

As necessidades N6 e N7 não são atendidas por completo e voltam como limitações na seção 5.5. Nenhuma das alternativas avaliadas atendia às sete ao mesmo tempo, e a escolha considerou quais lacunas podem ser contornadas no método e quais precisam ficar registradas.

5 ALTERNATIVAS AVALIADAS E BASE SELECIONADA

5.1 Comparação entre alternativas

Tabela 2 - Conjuntos de dados considerados

Alternativa	Conteúdo	Rótulo disponível	Volume	Avaliação
Conjunto próprio (FALCÃO e DataJud, TRT-16)	Sentenças trabalhistas de 1º grau e metadados	Deferimento do pedido, 89% por regra, sem conferência humana	413 casos treináveis	Descartado (seção 3.3)
API pública do DataJud (CNJ)	Metadados e movimentos codificados pela tabela do CNJ	Nenhum rótulo de situação	Milhões de processos	Descartada para treino: a situação teria de ser inferida dos próprios movimentos, o que tornaria o rótulo circular. Segue como fonte do MVP
VICTOR (Luz de Araujo et al., 2020)	Peças de recursos extraordinários do STF	Tipo de documento e tema de repercussão geral	45.532 processos e 692.966 documentos	Descartado: trata da classificação de peças, não da situação do processo
Decisões do TJAL (Lage-Freitas et al., 2022)	Ementas e decisões de segundo grau	Resultado da decisão	4.043 casos	Descartado: trata do resultado do julgamento, não da situação
Brazilian Legal Proceedings (Polo, 2021)	Movimentações de processos estaduais de SP e RJ	Situação do processo, atribuída por advogados	6.449 processos e 2.904.255 movimentações sem rótulo	**Selecionada**

Fonte: elaborado pela equipe (2026).

A comparação deixou de lado bases que só existem para outra tarefa. VICTOR e o conjunto do TJAL são bem documentados e maiores ou comparáveis em volume, mas o rótulo de cada um responde a outra pergunta, e reaproveitá-los exigiria uma nova rotulagem com o mesmo custo que inviabilizou o conjunto próprio. O DataJud tem o volume e o formato do MVP, mas não tem rótulo. A base selecionada é a única entre as avaliadas cujo rótulo coincide com uma informação que o sistema já armazena.

5.2 Identificação da base selecionada

Tabela 3 - Identificação da base selecionada

Item	Descrição
Nome	Brazilian Legal Proceedings
Autor	Felipe Maia Polo
Repositório e link	Kaggle: https://www.kaggle.com/datasets/felipepolo/brazilian-legal-proceedings

Item	Descrição
Versão usada	2, publicada em 14/05/2021; integridade conferida por SHA-256 (seção 11)
Origem dos dados	Movimentações de processos das justiças estaduais de São Paulo e do Rio de Janeiro. A rotulagem foi feita por advogados. A descrição da base registra agradecimento à empresa Tikal Tech
Estudo de referência	Polo, Ciochetti e Bertolo (2021), apresentado na ICAIL 2021
Licença	Declarada na fonte como "Unknown"
Formato	Dois arquivos JSON, distribuídos compactados
Tamanho	labeled.json com 127,6 MB e unlabeled.json com 530,1 MB
Registros	6.449 processos rotulados, com 545.843 movimentações; 2.904.255 movimentações sem rótulo

Fonte: elaborado pela equipe (2026).

5.3 Estrutura e principais atributos

O arquivo *labeled.json* é um objeto em que cada chave identifica um processo. Cada processo tem dois campos: *label*, com a situação, e *texts*, com as movimentações indexadas pela posição, em que a chave -1 é a mais recente, -2 a anterior, e assim por diante. O arquivo *unlabeled.json* é um objeto plano que associa um identificador a um texto de movimentação, sem indicar o processo de origem. Não há campo de data, tribunal, classe processual ou partes: tudo o que se sabe de um processo está no texto das suas movimentações.

Tabela 4 - Atributos da base original

Atributo	Tipo	Descrição	Valores observados
Chave do processo	Texto	Identificador do processo, sem número CNJ	6.449 valores distintos
label	Categórico	Situação atribuída por advogado	H:Arquivado (3.040), H:Ativo (2.917), H:Suspenso (492)
texts	Dicionário de textos	Movimentações do processo, por posição	De 1 a 2.659 por processo; mediana de 60
Texto da movimentação	Texto livre	Descrição do ato, gerada pelo sistema do tribunal	Mediana de 81 caracteres; máximo de 160.093
unlabeled (chave e texto)	Texto livre	Movimentações sem rótulo e sem vínculo com processo	2.904.255 registros, 1.305.090 textos distintos, 22 vazios

Fonte: elaborado pela equipe a partir de Polo (2021).

5.4 Justificativa da escolha e relação com o problema

A ligação entre o problema e a base é direta. O advogado quer saber a situação do processo; para isso, interpreta as movimentações (N1) com base na própria experiência, e a base oferece essas mesmas movimentações ao lado da conclusão de um advogado (N2), nos três valores que o MVP já usa (N4). A variável-alvo existe pronta, sem regra intermediária de rotulagem, o que elimina o principal defeito do conjunto anterior.

O volume também muda o que pode ser afirmado. Com 6.449 processos, é possível reservar um conjunto de teste com mais de mil casos antes de qualquer experimento e ainda calcular intervalos de confiança que não incluem o zero. As movimentações sem rótulo, embora não sirvam para treino supervisionado, permitem testar se um vocabulário aprendido em um volume maior de texto melhora o modelo. Por fim, a existência de um estudo publicado com a mesma base fornece uma referência externa para os resultados.

5.5 Limitações iniciais

Ramo de justiça. A base é da justiça estadual de São Paulo e do Rio de Janeiro, enquanto o MVP consulta tribunais do trabalho e federais. O vocabulário das movimentações muda de um sistema para outro, e no DataJud os movimentos chegam como nomes padronizados da tabela do CNJ, não como texto livre.

Ausência de datas. Sem data por movimentação, não é possível a divisão temporal que o projeto adota como regra de avaliação. A seção 8.4 descreve a alternativa e o seu custo.

Momento do rótulo. A base não informa quando cada processo foi rotulado. A situação é uma fotografia de um instante desconhecido e pode ter mudado depois.

Dados pessoais e licença. Os textos trazem nomes de partes, advogados e servidores. Somados à licença declarada como "Unknown", esses dados impedem a redistribuição dos arquivos no repositório.

Desbalanceamento e origem implícita. A classe suspenso responde por 7,6% dos processos, e o tribunal de origem não é informado, precisando ser inferido do formato dos textos.

6 LIMPEZA E PREPARAÇÃO DOS DADOS

6.1 Processo de limpeza

A limpeza é feita pelo script *src/ted02_limpar_e_explorar.py*, depois que o script da TED 01 baixa os arquivos e confere o SHA-256 da versão usada. O processo tem quatro passos, aplicados igualmente às bases com e sem rótulo.

No primeiro passo, cada movimentação é normalizada: a codificação Unicode é unificada (forma NFKC), o espaço não separável vira espaço comum, quebras de linha e caracteres de controle são removidos e espaços repetidos são colapsados. O prefixo de formulário "Tipo do Movimento:", presente no início das movimentações de um dos tribunais, é retirado do texto e usado apenas para inferir a origem.

No segundo passo, identificadores são trocados por marcadores: número CNJ por *tkcnj*, CPF e CNPJ por *tkdoc*, número de OAB por *tkoab*, e-mail por *tkemail*, valores em reais por *tkvalor*, datas por *tkdata* e demais números por *tknum*. Antes da troca das datas, o ano é extraído para a variável de referência temporal.

No terceiro passo, nomes de pessoas são trocados por *tknome*. Como nomes não seguem padrão fixo, a equipe construiu um léxico a partir dos próprios textos. São candidatas as palavras que aparecem antes de um número de OAB ou depois de um papel processual (parte, autor, réu, exequente, advogado, juiz); numa segunda passada, entram também as palavras escritas junto a um nome já identificado, como sobrenomes que nunca aparecem perto da OAB. Uma candidata só fica no léxico se aparecer em minúscula em menos de 2% das ocorrências e raramente abrir uma movimentação, o que separa sobrenomes como Silva de palavras como Decisão ou Despacho. Siglas e órgãos sempre grafados com inicial maiúscula, como Tribunal, Vara, OAB e STJ, ficam de fora por uma lista fixa montada a partir da inspeção das palavras mais substituídas. Seis sobrenomes encontrados na auditoria do modelo, que também são palavras comuns e por isso não passam no filtro de minúsculas, foram acrescentados à mão. O léxico final tem 51.337 palavras e gerou 459.511 substituições na base rotulada.

No quarto passo, as movimentações são agrupadas por processo, as variáveis derivadas são calculadas e os processos duplicados são removidos. Os testes de *src/test_limpeza.py*

conferem as regras de normalização, de mascaramento, de leitura do arquivo sem rótulo e de extração do ano.

6.2 Problemas de qualidade e tratamentos

A Tabela 5 reúne os problemas encontrados, a quantidade de ocorrências na base rotulada, o tratamento aplicado e o motivo de cada decisão.

Tabela 5 - Problemas de qualidade, tratamentos e justificativas

Problema	**Ocorrências**	**Tratamento**	**Justificativa**
Rótulos com prefixo "H:" e inicial maiúscula	6.449 rótulos	Prefixo removido e texto em minúsculas	Padronizar com os valores do MVP
Processos duplicados (mesmo rótulo e mesma sequência)	86 processos	Mantida uma cópia de cada	Evitar que o mesmo caso apareça no treino e no teste
Espaço não separável, quebras e caracteres de controle	6.621 movimentações	Normalização Unicode e espaços colapsados	Textos iguais escritos de formas diferentes contariam como distintos
Prefixo de formulário "Tipo do Movimento:"	Processos de um dos tribunais	Retirado do texto; usado para inferir a origem	O modelo aprenderia a reconhecer o tribunal em vez da situação
Movimentações muito longas	5.116 acima de 2.000 caracteres; máximo de 160.093	Truncadas em 2.000 caracteres, perto do percentil 99	O tipo do ato fica no início; decisões transcritas por inteiro dominariam a representação
Identificadores (CNJ, CPF ou CNPJ, OAB, e-mail, valores)	7.810, 1.549, 254.533, 317 e 5.395	Substituídos por marcadores	Dados pessoais; números únicos não generalizam
Datas e outros números	193.053 datas e 807.894 números	Substituídos por *tkdata* e *tknum*	Mesmo motivo; o ano é extraído antes
Nomes de pessoas	459.511 substituições	Substituídos por *tknome* com o léxico descrito em 6.1	Proteção de dados (LGPD) e risco de o modelo memorizar escritórios
Datas impossíveis ou futuras	736 datas	Ignoradas no cálculo do ano	Dia acima de 31, mês acima de 12 ou ano fora de 1990 a 2021 indicam erro de digitação
Processos sem data aproveitável	585 processos	Mantidos, com ano ausente	O ano não é entrada do modelo; excluir esses casos mudaria a amostra sem ganho
Movimentações repetidas em sequência	11.322 movimentações	Mantidas	A repetição também registra o andamento, e removê-la alteraria a janela das últimas movimentações
Processos com menos de 5 movimentações	14 processos	Mantidos	A janela usa as movimentações disponíveis
Processos com as mesmas 5 últimas movimentações	27 grupos com 83 processos; 2 grupos com rótulos diferentes (4 processos)	Mantidos, sempre do mesmo lado na divisão dos dados	Evitar vazamento entre treino e teste; a divergência é ruído de rótulo e foi preservada

Problema	Ocorrências	Tratamento	Justificativa
Valores extremos de tamanho do histórico	Até 2.659 movimentações e 503.574 caracteres	Mantidos	São processos reais; o modelo usa só as últimas movimentações, e o tamanho total não entra
Textos vazios na base sem rótulo	22 textos	Descartados	Sem conteúdo
Variáveis redundantes	Correlação de Spearman de 0,917 entre número de movimentações e total de caracteres	Mantidas só para análise	Medem a mesma coisa; nenhuma entra no modelo final

Fonte: elaborado pela equipe (2026).

Nenhuma movimentação ficou vazia depois da limpeza. Os 86 duplicados eram cópias exatas, com o mesmo rótulo; não houve duas cópias idênticas com situações diferentes. Já os 4 processos que compartilham as cinco últimas movimentações com outro processo de situação diferente mostram que o rótulo tem algum ruído: o mesmo final de histórico recebeu conclusões distintas. Esses casos foram mantidos, porque retirá-los esconderia uma dificuldade real da tarefa.

O mascaramento de nomes foi revisto três vezes, sempre a partir da inspeção dos termos de maior peso do modelo. Antes do léxico, nomes de advogados apareciam entre esses termos. A primeira versão do léxico capturava termos institucionais, como tribunal, vara e número, e escondia a própria palavra OAB, o que impedia a marcação *tkoab*. A segunda ainda deixava passar sobrenomes que nunca aparecem perto de uma OAB, o que levou à segunda passada descrita em 6.1. A terceira tratou os sobrenomes que também são palavras comuns, como Guerra e Parada. Uma regra mais ampla, que mascarasse toda palavra com inicial maiúscula escrita logo depois de um nome, foi medida e descartada, porque apagaria termos como petição, protocolo e audiência. O método continua heurístico, e um nome isolado pode escapar; por isso os textos tratados também ficam fora do repositório.

6.3 Base após o tratamento

A base tratada tem 6.363 processos e 539.286 movimentações. A Tabela 6 descreve as variáveis de cada processo. A versão com texto fica em *data/processed/processos.jsonl*, fora do Git; o repositório guarda *resultados/ted02_base_tratada_metadados.csv*, com todas as colunas exceto o texto.

Tabela 6 - Variáveis da base tratada

Variável	Tipo	Como foi obtida	Uso
id	Texto	Chave original do processo	Rastreio
classe	Categórico	Rótulo sem o prefixo "H:"	Variável-alvo
movs	Lista de textos	Movimentações limpas, da mais recente para a mais antiga	Entrada do modelo
origem	Categórico	RJ (provável) quando mais da metade das movimentações tem o prefixo de formulário; SP (provável) nos demais casos	Análise de generalização
ano_ref	Inteiro	Maior ano válido citado nas 10 movimentações mais recentes	Análise temporal
n_mov	Inteiro	Número de movimentações	Análise; testada no modelo
chars_total e chars_medio	Numérico	Total e média de caracteres por processo	Análise
grupo	Texto	Resumo criptográfico (SHA-1) das 5 últimas movimentações	Divisão dos dados sem vazamento

Fonte: elaborado pela equipe (2026).

A origem é uma inferência. Na conferência, quase todos os processos marcados como RJ (provável) citam o Rio de Janeiro no texto, e a grande maioria dos demais cita São Paulo, mas não há campo que confirme o tribunal. O ano de referência aproxima o período da última atividade do processo, e não a data de início. As duas variáveis servem para analisar o comportamento do modelo em recortes e não entram como atributo de previsão.

7 ANÁLISE EXPLORATÓRIA

7.1 Estatísticas descritivas

Tabela 7 - Estatísticas descritivas por classe

Classe	Proc.	%	Mov. (mediana)	Mov. (IIQ)	Mov. (média)	Caract. (mediana)	Caract. por mov.	Ano (mediana)
arquivado	3.005	47,2%	54	32 a 94	72,1	8.147	146,2	2.017
ativo	2.868	45,1%	63	39 a 121	94,7	9.548	148,9	2.018
suspenso	490	7,7%	81	49 a 138	104,0	11.529	141,1	2.017
Total	**6.363**	**100%**	**60**	**36 a 110**	**84,8**	**8.985**	**147,2**	**2.018**

Fonte: elaborado pela equipe a partir de Polo (2021).

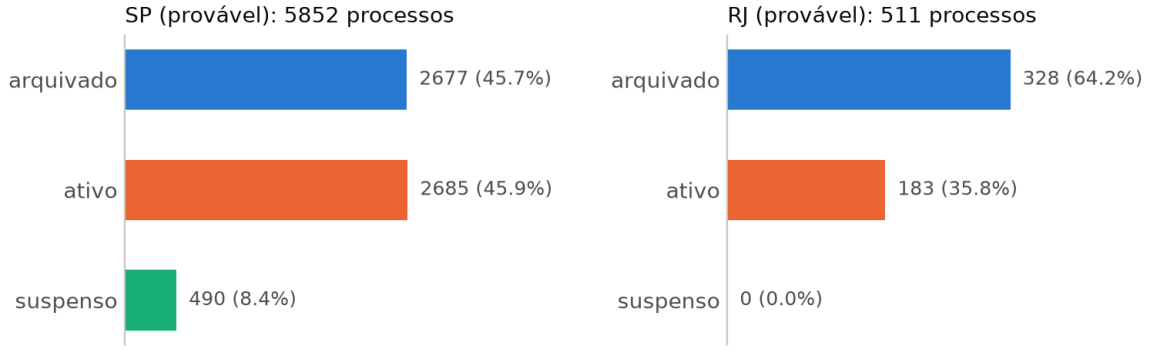
Na Tabela 7, Proc. indica o número de processos, Mov. o número de movimentações por processo, IIQ o intervalo entre o primeiro e o terceiro quartis e Caract. o número de caracteres.

O processo típico tem 60 movimentações, com metade dos casos entre 36 e 110. A distribuição tem cauda longa: a média (84,8) fica acima da mediana, 5% dos processos passam de 221 movimentações e o maior chega a 2.659. O tamanho médio de cada

movimentação, ao contrário, é estável entre as classes, perto de 147 caracteres. A classe suspenso reúne os históricos mais longos, e a arquivado, os mais curtos.

7.2 Distribuição das classes e origem dos processos

Figura 1 - Distribuição das classes por origem provável do processo



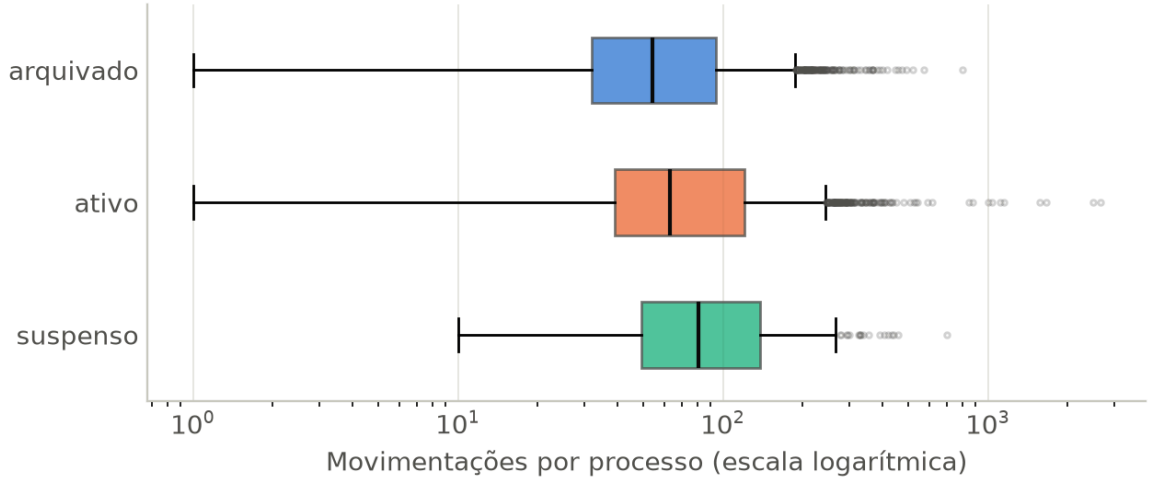
Fonte: elaborado pela equipe a partir de Polo (2021).

Na base tratada, 47,2% dos processos estão arquivados, 45,1% ativos e 7,7% suspensos. Com uma classe tão pequena, a acurácia sozinha engana: um modelo que nunca previsse suspenso poderia acertar até 92,3% dos casos. Por isso a métrica principal da seção 8 dá o mesmo peso às três classes.

A Figura 1 mostra uma diferença mais grave entre as origens. Os 5.852 processos de SP (provável) têm as três situações, enquanto os 511 de RJ (provável) não têm nenhum suspenso. A associação entre origem e classe é significativa, mas fraca (V de Cramér de 0,117), e a ausência de suspensos pode vir tanto da forma como a base foi montada quanto do modo como aquele tribunal registra a suspensão. Para o projeto, a consequência é que qualquer modelo treinado só com os processos do Rio não aprende a reconhecer a suspensão, o que a seção 8.10 confirma.

7.3 Tamanho do histórico

Figura 2 - Número de movimentações por processo, por classe



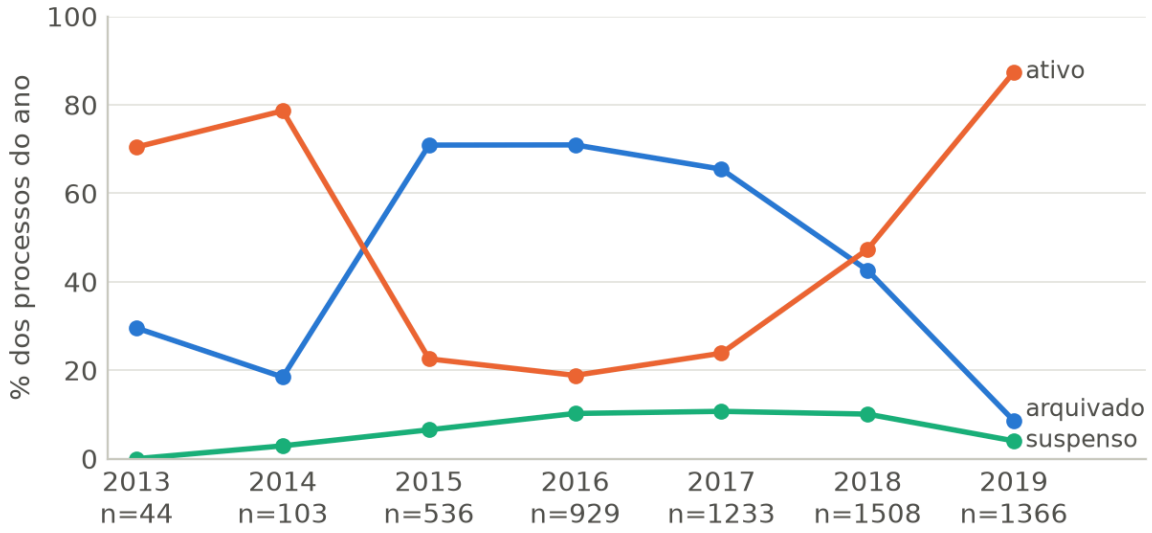
Fonte: elaborado pela equipe a partir de Polo (2021).

As medianas são de 54 movimentações para arquivados, 63 para ativos e 81 para suspensos. O teste de Kruskal-Wallis indica diferença entre as classes ($H = 152{,}1$, $p < 0{,}001$), mas o tamanho do efeito é pequeno: o eta ao quadrado de 0,024 significa que o número de movimentações explica cerca de 2% da variação entre classes. As caixas da Figura 2 se sobrepõem quase por inteiro.

O padrão faz sentido no processo civil. Processos suspensos costumam ser execuções em que houve várias tentativas de localizar bens ou o devedor antes da suspensão, e cada tentativa gera movimentações. Ainda assim, o tamanho do histórico não serve para separar as classes, o que antecipou o resultado do experimento E4 da seção 8.

7.4 Dimensão temporal

Figura 3 - Participação de cada classe por ano de referência



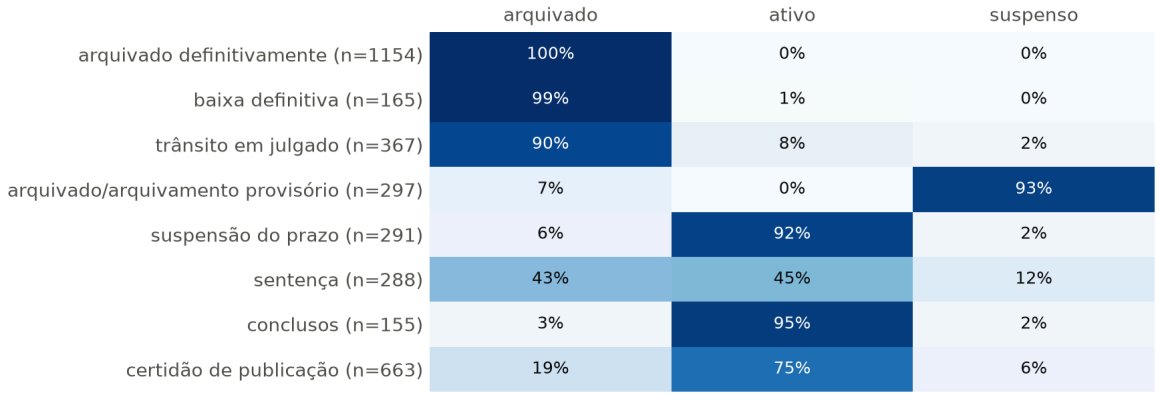
Fonte: elaborado pela equipe a partir de Polo (2021).

Entre os processos com última atividade em 2015, 70,9% estão arquivados; entre os de 2019, 87,4% estão ativos. A partir de 2015, a Figura 3 mostra a troca gradual entre as duas classes. Os anos de 2013 e 2014 têm poucos processos (44 e 103) e não seguem o padrão. A explicação está na forma como o ano foi construído e não em uma mudança do Judiciário: um processo arquivado para de gerar movimentações, e o seu último registro fica no passado; um processo ativo continua gerando registros até a data da coleta. O ano funciona, portanto, como variável de confusão, porque carrega informação sobre a classe por um caminho que não existe no uso real do modelo.

Duas decisões decorrem daí. O ano não entra como atributo de previsão, e as avaliações temporais da seção 8.10 precisam ser lidas sabendo que a distribuição de classes do período de teste é muito diferente da do treino.

7.5 Conteúdo da última movimentação

Figura 4 - Situação dos processos segundo expressões presentes na última movimentação



Fonte: elaborado pela equipe a partir de Polo (2021).

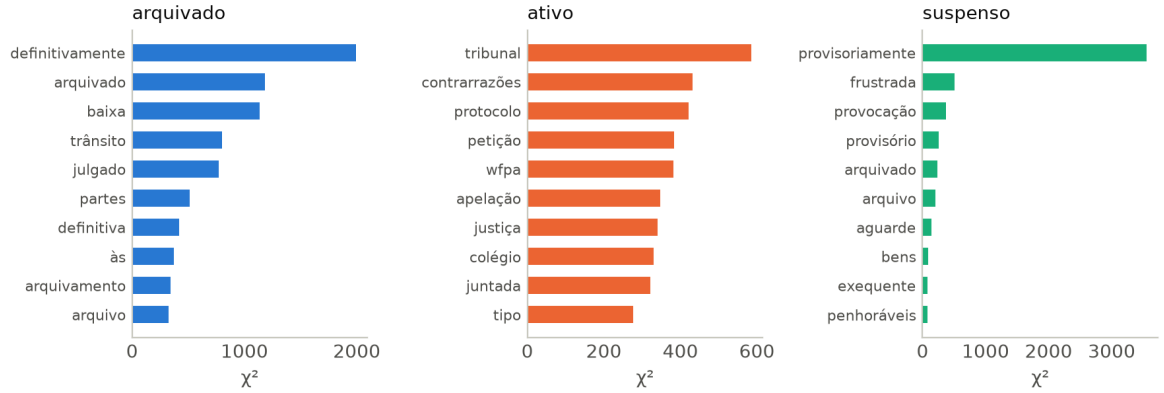
A Figura 4 cruza a situação com expressões da última movimentação. Algumas quase determinam a classe: dos 1.154 processos cuja última movimentação contém "arquivado definitivamente", 1.152 estão arquivados, e "baixa definitiva" aparece em 164 arquivados de 165 casos. "Trânsito em julgado" indica arquivamento em 90,2% dos casos.

Outras expressões enganam quem procura palavras isoladas. "Arquivado provisoriamente" e "arquivamento provisório" levam a palavra arquivado, mas 92,9% desses processos estão suspensos: é o registro usado quando a execução fica parada à espera de bens. No sentido oposto, "suspensão do prazo" aparece em processos ativos em 91,8% das vezes, porque se refere à suspensão de prazos em feriados ou recessos, e não do processo. Uma regra que procurasse "arquivad" ou "suspens" erraria justamente nesses casos.

A palavra "sentença" não define a situação (124 arquivados, 129 ativos e 35 suspensos), já que uma sentença pode ser seguida de recurso ou de execução. "Conclusos" indica processo ativo em 94,8% dos casos, pois o processo está com o juiz para decisão. Esses padrões orientaram a regra usada como linha de base na seção 8 e a escolha de representar pares de palavras, e não só palavras isoladas.

7.6 Termos que distinguem as classes

Figura 5 - Termos mais associados a cada classe nas cinco últimas movimentações (estatística qui-quadrado)



Fonte: elaborado pela equipe a partir de Polo (2021).

A Figura 5 ordena, para cada classe, os termos mais associados a ela nas cinco últimas movimentações, entre os que aparecem em pelo menos 20 processos. O termo de maior associação em toda a análise é "provisoriamente" ($\chi^2 = 3.554$), ligado aos suspensos, seguido na mesma classe por "frustrada" (execução frustrada), "provocação" (arquivo à espera de provocação da parte) e "penhoráveis", vocabulário da suspensão da execução por falta de bens prevista no art. 921, III, do Código de Processo Civil. Nos arquivados, dominam "definitivamente", "baixa" e "trânsito". Nos ativos, os termos são de recurso e de peticionamento, como "tribunal", "contrarrazões", "protocolo" e "apelação".

Dois termos da lista dos ativos pedem cuidado. "Colégio" vem de Colégio Recursal, instância de recurso dos juizados especiais paulistas, e indica recurso em andamento. "Wfpa" é um código de sistema, sem significado jurídico. A presença dele mostra que parte do sinal vem do formato de registro de um tribunal específico, e esse sinal não se transfere para outros tribunais.

7.7 Relações entre variáveis e base sem rótulo

Entre as variáveis numéricas, o número de movimentações e o total de caracteres têm correlação de Spearman de 0,917 e medem praticamente a mesma coisa. A correlação entre número de movimentações e ano de referência é fraca (0,241): processos com atividade recente tendem a ter históricos um pouco maiores. O tamanho médio das movimentações

quase não varia entre classes (eta ao quadrado de 0,0015). Nenhuma variável numérica separa as classes; o sinal está no texto.

Na base sem rótulo, as 2.904.255 movimentações têm 1.305.090 textos distintos, que caem para 679.620 depois da limpeza, já que muitos diferiam só por números, datas ou nomes. Os 100 textos mais frequentes respondem por 23,5% do total, e 66,9% das movimentações rotuladas têm um texto idêntico na base sem rótulo. As duas bases vêm, portanto, dos mesmos sistemas, e a base sem rótulo pode servir para aprender vocabulário, hipótese testada no experimento E5.

7.8 Síntese da análise e consequências para o projeto

A análise exploratória levou a cinco decisões, todas retomadas na modelagem. O sinal está concentrado nas movimentações mais recentes, o que levou a testar janelas curtas do histórico. Como a classe suspenso é pequena, a métrica principal precisa pesar as classes por igual, e o treino usa pesos balanceados. Como o significado depende de expressões e não de palavras soltas, a representação inclui pares de palavras. O ano é uma variável de confusão e fica fora do modelo. Por último, a origem e o período passam a ser usados para medir a generalização, e não para treinar.

A análise também confirmou a mudança de rumo registrada na seção 3.3. A base não tem pedidos, sentenças classificadas por resultado nem identificação de vara, de modo que o problema de estimar deferimento por unidade julgadora não pode ser tratado com ela. O problema de aprendizado passou a ser a classificação da situação do processo. Também ficou estabelecido que a divisão temporal, regra de avaliação do projeto, não é possível como avaliação principal, e o desvio está registrado na seção 10.

8 MODELAGEM

8.1 Definição do problema de aprendizado

O problema é de classificação supervisionada com três classes. A unidade de análise é o processo; a entrada é o texto das movimentações mais recentes, já limpo; a variável-alvo é a situação atribuída pelos advogados (arquivado, ativo ou suspenso). A previsão é feita depois da última movimentação disponível e usa apenas o que já estava registrado nesse momento. A saída é uma probabilidade para cada classe: a maior define a sugestão e, abaixo de um limiar de confiança, o modelo se abstém.

8.2 Abordagem e justificativa

A abordagem escolhida representa o texto por TF-IDF de palavras e pares de palavras e usa um classificador linear. Quatro motivos sustentam a escolha. A análise exploratória mostrou que o sinal está em expressões curtas, como "arquivado provisoriamente", que os pares de palavras capturam. O conjunto de desenvolvimento, com 5.090 processos, é pequeno para treinar redes profundas do zero, e o estudo de referência obteve ganho pequeno das redes com BERT sobre modelos com TF-IDF. O modelo linear permite ler os pesos de cada termo, o que foi necessário para auditar nomes residuais. E a regressão logística fornece probabilidades, base da regra de abstenção. O treino leva segundos em um computador comum.

8.3 Preparação dos dados e seleção de variáveis

O texto é dividido em palavras de duas ou mais letras, em minúsculas, e representado por TF-IDF com palavras isoladas e pares de palavras, frequência sublinear e descarte de termos presentes em menos de dois processos. A última movimentação e as quatro anteriores formam dois blocos separados, de modo que o modelo distingue um termo que está no registro mais recente de um que apareceu antes. Nas figuras, os termos do primeiro bloco aparecem com o prefixo "U:" e os do segundo com "A:".

Ficaram fora do modelo a origem, que identifica o tribunal e não existiria nos dados do MVP; o ano, variável de confusão; o total de caracteres, redundante; e o número de

movimentações, que não trouxe ganho (experimento E4). A base sem rótulo foi usada apenas no experimento E5.

8.4 Divisão dos dados e protocolo de avaliação

A regra do projeto prevê divisão temporal em todas as avaliações. Sem data por movimentação, essa divisão não é possível como avaliação principal. A alternativa adotada foi separar 20% dos processos para teste antes de qualquer experimento, com estratificação por classe e agrupamento pela variável grupo, de modo que processos com as mesmas cinco últimas movimentações fiquem sempre do mesmo lado. O desenvolvimento ficou com 5.090 processos e o teste com 1.273 (601 arquivados, 574 ativos e 98 suspensos). A lista de processos de cada lado está em *resultados/ted03_particao.csv*.

Todas as escolhas (janela, algoritmo, atributos e hiperparâmetros) foram feitas por validação cruzada de cinco dobras dentro do desenvolvimento, com o mesmo agrupamento e semente fixa. A regra de seleção foi definida antes dos experimentos: vence o maior F1 macro médio, e uma diferença menor que o desvio padrão entre dobras é tratada como empate, resolvido a favor da opção mais simples ou que fornece probabilidades. Na busca automática de hiperparâmetros do E6, vence a combinação de maior média. O teste avalia apenas o modelo escolhido. Como verificação complementar, a seção 8.10 treina com um tribunal ou período e testa com outro.

8.5 Métricas

A métrica principal é o F1 macro, média simples do F1 das três classes, que dá à classe suspenso o mesmo peso das demais. A acurácia é apresentada para comparação com o estudo de referência, acompanhada da acurácia balanceada. Precisão e revocação por classe mostram onde estão os erros; o erro mais caro para o advogado é classificar como arquivado um processo ativo, porque no MVP isso interromperia o acompanhamento.

A calibração é medida pela perda logarítmica e pelo erro esperado de calibração (ECE), que compara a confiança declarada com a taxa de acerto observada. Ela é necessária para a abstenção: um limiar de 0,8 só faz sentido se as previsões com essa confiança acertam perto de 80% das vezes ou mais. A incerteza do teste é estimada por *bootstrap* com 2.000

reamostragens, que geram intervalos de 95%. O ganho sobre a linha de base é calculado em cada reamostragem, com os mesmos casos para os dois modelos.

8.6 Linhas de base e experimentos

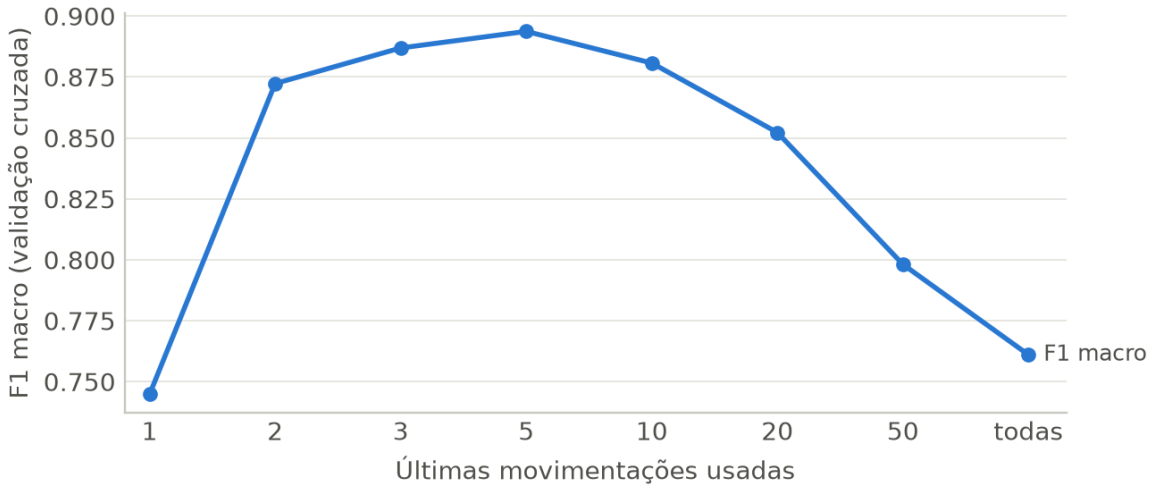
Duas linhas de base servem de referência. A classe majoritária, que prevê sempre arquivado, tem F1 macro de 0,214 na validação cruzada. A regra de palavras-chave aplica à última movimentação os padrões da seção 7.5: termos de suspensão ou arquivamento provisório indicam suspenso; arquivamento, baixa definitiva ou trânsito em julgado indicam arquivado; o restante é ativo. Ela alcança F1 macro de 0,775 e acurácia de 81,3% no desenvolvimento. A Tabela 8 resume os experimentos.

Tabela 8 - Resultados da validação cruzada no conjunto de desenvolvimento

Etapa	Configuração	F1 macro (desvio)	Acurácia	Decisão
Base	Classe majoritária	0,214 (0,000)	47,2%	Referência
Base	Regra de palavras-chave	0,775	81,3%	Referência
E1	Janela de 1 movimentações	0,745 (0,013)	82,1%	-
E1	Janela de 3 movimentações	0,887 (0,013)	92,4%	-
E1	Janela de 5 movimentações	0,894 (0,010)	92,8%	Escolhida
E1	Janela de 10 movimentações	0,881 (0,007)	92,2%	-
E1	Todas as movimentações	0,761 (0,024)	84,6%	-
E3	Naive Bayes complementar	0,637 (0,011)	81,9%	-
E3	SVM linear	0,900 (0,015)	93,2%	Empate com a escolhida
E3	Regressão logística	0,894 (0,010)	92,8%	Escolhida (probabilidades)
E3	Gradient boosting + SVD	0,853 (0,019)	89,7%	-
E4	Última separada das 4 anteriores	0,900 (0,011)	92,8%	Escolhida
E4	Mesmo arranjo com log do número de movimentações	0,900 (0,010)	92,9%	Sem ganho
E5	Vocabulário e IDF aprendidos na base sem rótulo	0,900 (0,011)	93,3%	Ganho abaixo do desvio
E6	Busca em 20 combinações; melhor: C = 30, pesos balanceados, pares na última	0,901 (0,011)	-	Modelo final

Fonte: elaborado pela equipe a partir de Polo (2021).

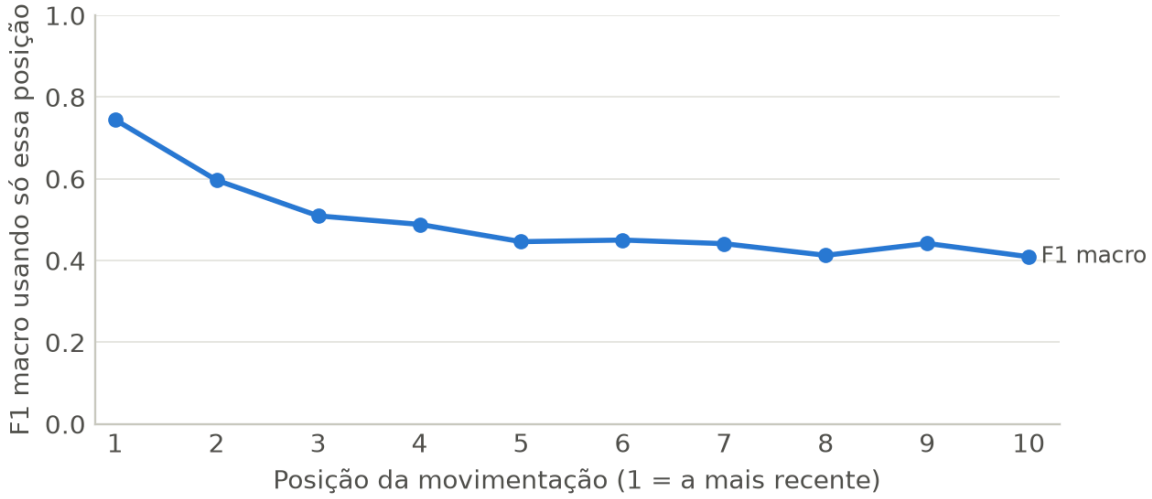
Figura 6 - F1 macro na validação cruzada segundo o número de movimentações usadas (E1)



Fonte: elaborado pela equipe a partir de Polo (2021).

O experimento E1 variou quantas movimentações recentes entram no texto. Só a última dá F1 macro de 0,745; com cinco, o valor sobe para 0,894, o melhor resultado; a partir daí cai, até 0,761 com o histórico inteiro. As movimentações antigas acrescentam mais ruído do que informação, porque descrevem fases que o processo já deixou para trás. A janela de cinco coincide com a usada no estudo de referência; a diferença para a janela de três ficou dentro da variação entre dobras.

Figura 7 - F1 macro usando apenas a movimentação de cada posição (E2)



Fonte: elaborado pela equipe a partir de Polo (2021).

O experimento E2 treinou um modelo para cada posição isolada. A última movimentação sozinha chega a 0,745; a segunda, a 0,597; a décima, a 0,409. A informação

cai depressa com a distância, mas as posições seguintes ainda superam a classe majoritária, o que explica o ganho de juntar as cinco últimas. Os pesos da seção 8.8 mostram um caso frequente: o arquivamento definitivo registrado na segunda ou terceira posição e seguido de atos administrativos, como certidões e remessas.

No experimento E3, a SVM linear (0,900) e a regressão logística (0,894) ficaram dentro de um desvio padrão uma da outra. Pela regra de seleção, a regressão logística foi mantida, por fornecer probabilidades. O gradient boosting sobre componentes SVD (0,853) e o Naive Bayes complementar (0,637) ficaram abaixo. O Naive Bayes combinou acurácia de 81,9% com F1 macro baixo, o padrão de quem erra muito na classe minoritária.

No E4, separar a última movimentação das anteriores levou o F1 macro de 0,894 para 0,900. A diferença ficou dentro da variação entre dobras, o que pela regra de seleção é um empate. O arranjo separado foi mantido mesmo assim, por interpretabilidade: ele permite saber se um termo pesou por estar na última movimentação ou nas anteriores, informação usada na seção 8.8 e útil para explicar a sugestão ao advogado. Acrescentar o logaritmo do número de movimentações não ajudou (0,900), como a análise da seção 7.3 indicava. No E5, aprender vocabulário e IDF na base sem rótulo deu 0,900, diferença média de 0,0002 sobre o arranjo do E4, positiva em duas das cinco dobras e menor que o desvio entre dobras (0,011). O resultado não foi adotado: nesta base, o vocabulário da base sem rótulo não acrescentou informação. A busca do E6 manteve os pesos balanceados e os pares de palavras na última movimentação e trocou o C = 10 usado até então por C = 30, uma regularização mais fraca, com F1 macro de 0,901 contra 0,900 do arranjo do E4. A diferença é desprezível e mostra que o desempenho é pouco sensível a C nessa faixa; como a busca adota a combinação de maior média, o modelo final usa C = 30.

8.7 Resultados no conjunto de teste

Tabela 9 - Desempenho no conjunto de teste, com intervalos de 95%

Modelo	F1 macro	Intervalo do F1	Acurácia	Intervalo da acurácia	Acurácia balanceada
Classe majoritária	0,214	-	47,2%	-	0,333
Regra de palavras-chave	0,750	[0,714; 0,781]	79,3%	[76,9%; 81,4%]	0,725
Regressão logística	**0,885**	[0,857; 0,909]	**92,2%**	[90,6%; 93,6%]	0,874

Fonte: elaborado pela equipe a partir de Polo (2021).

No teste, o modelo obteve F1 macro de 0,885, com intervalo de [0,857; 0,909], e acurácia de 92,2%. O ganho de F1 macro sobre a regra de palavras-chave ficou entre 0,106 e 0,166, intervalo que não inclui o zero. O valor do teste ficou abaixo da validação cruzada (0,901), diferença compatível com o tamanho do teste: o intervalo do teste inclui o valor da validação. A regra, por sua vez, foi construída com padrões observados na base inteira, inclusive no teste, o que a favorece; a comparação, portanto, não exagera a vantagem do modelo.

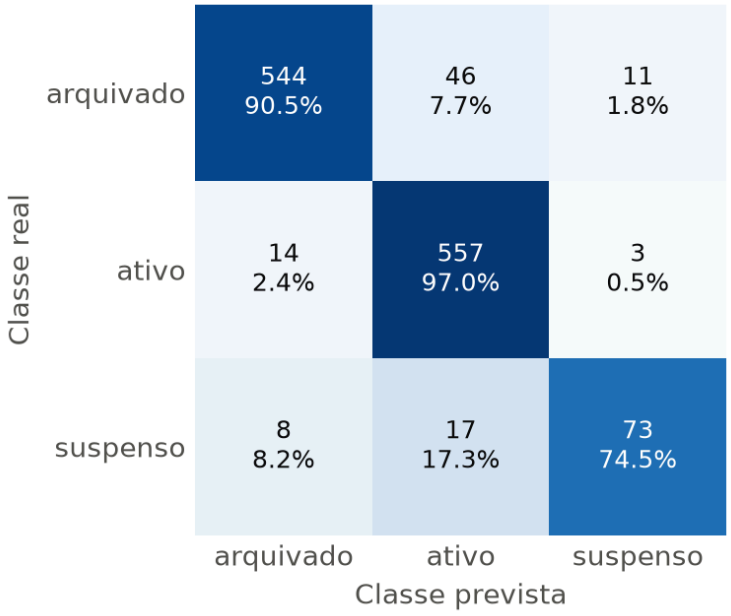
Tabela 10 - Precisão, revocação e F1 por classe no teste

Classe	Casos	Precisão (modelo)	Revocação (modelo)	F1 (modelo)	Precisão (regra)	Revocação (regra)	F1 (regra)
arquivado	601	0,961	0,905	0,932	0,959	0,661	0,782
ativo	574	0,898	0,970	0,933	0,704	0,974	0,817
suspenso	98	0,839	0,745	0,789	0,815	0,541	0,650

Fonte: elaborado pela equipe a partir de Polo (2021).

O ganho sobre a regra se concentra onde a análise exploratória apontava. Nos arquivados, a regra tem precisão alta, mas revocação de 0,661: deixa de reconhecer arquivamentos que não estão escritos na última movimentação. O modelo eleva essa revocação para 0,905. Nos suspensos, a revocação sobe de 0,541 para 0,745, ainda a menor entre as classes.

Figura 8 - Matriz de confusão do modelo no teste (contagem e proporção da classe real)



Fonte: elaborado pela equipe a partir de Polo (2021).

A Figura 8 mostra os 99 erros do teste. O mais frequente é classificar arquivados como ativos (46 casos). O erro mais caro para o MVP, ativo previsto como arquivado, ocorreu em 14 dos 574 processos ativos (2,4%). Dos 98 suspensos, 25 foram classificados em outra classe. Entre os recortes analisados, as maiores taxas de erro aparecem quando a última movimentação é uma sentença (17,0% de erro em 53 casos) ou uma certidão de publicação (13,9% em 137 casos), contra 7,8% no teste inteiro. Sozinhos, esses registros dizem pouco sobre o estado do processo: a sentença pode ser seguida de recurso, de cumprimento ou de arquivamento, e a certidão de publicação aparece nas três situações.

8.8 Variáveis relevantes

Figura 9 - Termos de maior peso para cada classe no modelo final



Fonte: elaborado pela equipe a partir de Polo (2021).

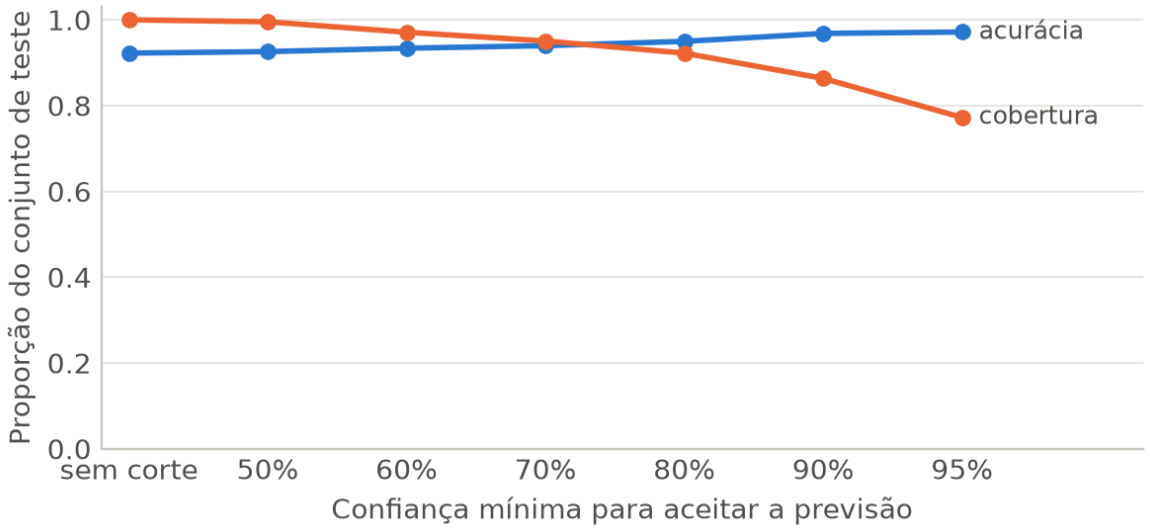
Os pesos do modelo repetem o que a análise exploratória havia mostrado. Arquivado é sustentado por "arquivado definitivamente", "definitivamente" e "baixa definitiva"; suspenso, por "arquivado provisoriamente" e "provisoriamente". Esses termos pesam mais no bloco das quatro movimentações anteriores do que na última, o que confirma que o arquivamento costuma ser seguido de atos administrativos e explica por que a janela de cinco supera a de uma. Na lista da classe suspenso aparecem também termos de processos criminais, como "crime" e "vara criminal", sinal de que a classe reúne situações de naturezas diferentes.

Os pesos dos ativos são bem menores (o maior é 2,94, contra 11,37 no topo dos arquivados) e se espalham por termos de tramitação. Os maiores vêm de fórmulas de remessa dos autos, como "observadas as formalidades de praxe" e "para tribunal", e do "cumprimento provisório" da sentença. Ativo funciona como a classe da ausência: o modelo o reconhece

mais pela falta de termos de encerramento ou de suspensão do que por um termo próprio. A lista dos 150 termos de maior peso em cada classe foi revisada à procura de nomes de pessoas, e essa revisão motivou as correções do mascaramento descritas na seção 6.2.

8.9 Confiança e abstenção

Figura 10 - Acurácia e cobertura no teste segundo a confiança mínima exigida



Fonte: elaborado pela equipe a partir de Polo (2021).

O erro esperado de calibração no teste foi de 0,032, e a perda logarítmica, de 0,278: a confiança declarada pelo modelo acompanha de perto a taxa de acerto. Isso permite usar a confiança como critério de abstenção. Com limiar de 0,8, o modelo sugere a situação de 92,2% dos processos e acerta 95,0% deles; com 0,9, a cobertura cai para 86,3% e a acurácia sobe para 96,8%.

Para o MVP, o limiar de 0,8 é um ponto de partida razoável. Em uma carteira de cem processos, cerca de 8 seriam encaminhados para leitura e, entre os demais, a sugestão erraria em média uma vez a cada 20 processos. O limiar é um parâmetro de produto e deve ser revisto com dados do próprio MVP.

8.10 Generalização entre tribunais e períodos

Tabela 11 - Desempenho com treino e teste em recortes diferentes

Treino	Teste	Processos (treino e teste)	Acurácia	F1 macro	Observação
SP (provável)	RJ (provável)	5.852 e 511	90,6%	0,910	F1 sobre duas classes; RJ não tem suspensos
RJ (provável)	SP (provável)	511 e 5.852	52,0%	0,300	Sem suspensos no treino; revocação de arquivados de 0,141
Até 2017	2018 e 2019	2.881 e 2.874	76,8%	0,753	Precisão de arquivados de 0,558
Até 2018	2019	4.383 e 1.366	92,2%	0,732	Revocação de suspensos de 0,382 em 55 casos

Fonte: elaborado pela equipe a partir de Polo (2021).

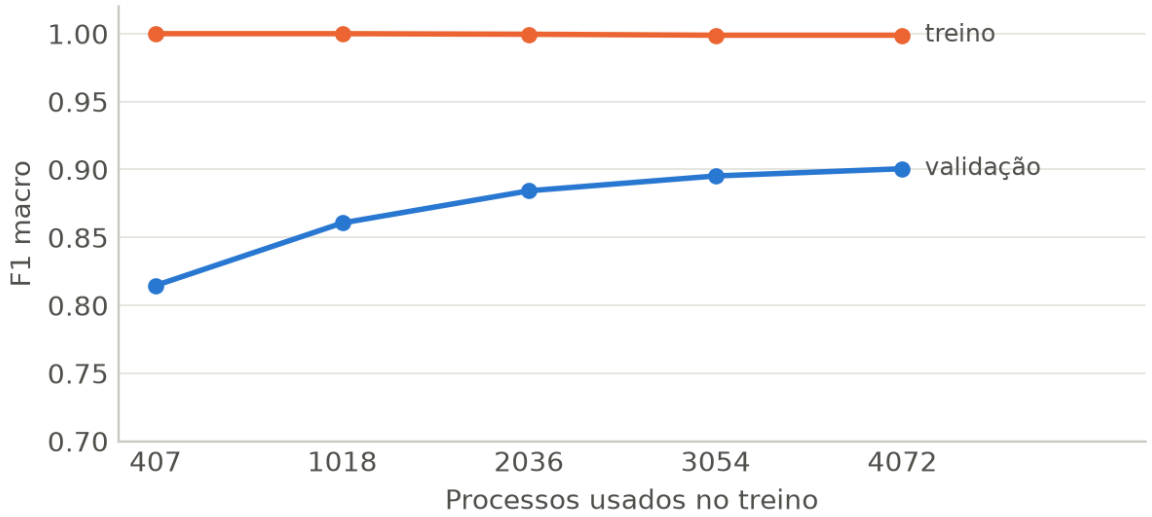
Treinado com os processos de São Paulo, o modelo mantém o desempenho nos do Rio de Janeiro (acurácia de 90,6%). O caminho inverso falha: treinado com os 511 processos do Rio, que não têm suspensos, o modelo acerta 52,0% dos processos de São Paulo, nunca prevê suspenso e reconhece apenas 14% dos arquivados, porque o vocabulário de arquivamento paulista não aparece no treino. Esse resultado é o principal alerta para o uso no MVP: um modelo que aprendeu o vocabulário de um tribunal não se transfere para outro com registros diferentes.

Nos recortes temporais, o F1 macro cai para 0,753 e 0,732, entre 0,13 e 0,15 abaixo do teste aleatório. Parte da queda vem da variável de confusão descrita em 7.4: o período de teste tem uma distribuição de classes muito diferente, com 87,4% de ativos em 2019. Outra parte vem de mudanças reais de vocabulário e de procedimento ao longo do tempo. O teste aleatório é, portanto, uma estimativa otimista; o temporal está mais perto da condição de uso, em que o modelo é treinado com o passado e aplicado a processos novos.

Como verificação de formato, o modelo foi aplicado a um processo real do TRT da 16ª Região obtido pela API do DataJud, com 71 movimentações convertidas em texto a partir do nome do movimento e dos complementos. A previsão foi arquivado, com confiança de 0,598, e 95,9% das palavras estavam no vocabulário do modelo. A confiança ficou abaixo do limiar de 0,8, de modo que no MVP o sistema não faria sugestão. A última movimentação, porém, é "Petição Embargos de declaração", ato de processo em andamento, o que indica que a previsão provavelmente está errada. É o tipo de falha esperado quando o vocabulário muda de tribunal, e a abstenção cumpriu o seu papel. Com um único processo e sem rótulo, a verificação mostra apenas que o caminho de dados do MVP funciona; não mede acerto.

8.11 Sobreajuste e curva de aprendizado

Figura 11 - F1 macro no treino e na validação segundo o número de processos de treino



Fonte: elaborado pela equipe a partir de Polo (2021).

O modelo final tem F1 macro de 0,999 no próprio treino, contra 0,901 na validação cruzada. A diferença indica sobreajuste: com dezenas de milhares de termos e poucos milhares de processos, o modelo memoriza parte do treino. A curva de validação passa de 0,815 com 407 processos para 0,901 com 4.072. O último trecho ainda acrescenta 0,005, de modo que mais dados rotulados melhorariam o resultado, com retorno cada vez menor.

8.12 Comparação com o estudo de referência

Polo, Ciochetti e Bertolo (2021) compararam doze combinações de representação (Word2Vec, Doc2Vec, TF-IDF e BERT) e classificador (LSTM, MLP e XGBoost) sobre as cinco últimas movimentações. A melhor, LSTM com BERT, teve acurácia de 0,93 e F1 macro de 0,89; com TF-IDF, o MLP chegou a 0,87 e o XGBoost a 0,88 de F1 macro. Os autores também observaram o pior desempenho na classe suspenso.

O modelo deste trabalho ficou no mesmo patamar (F1 macro de 0,901 na validação e 0,885 no teste). A comparação é apenas indicativa: o estudo usou divisão aleatória de 70%, 10% e 20% sem remoção de duplicados nem agrupamento de históricos iguais, e o pré-processamento também foi diferente. O resultado reforça a leitura da análise exploratória:

o sinal é lexical e concentrado em poucas expressões, e um modelo linear o captura tão bem quanto modelos maiores.

9 DISCUSSÃO DOS RESULTADOS

9.1 Contribuição do modelo para o problema

O modelo contribui para resolver o problema? Para o problema definido, sim. Ele supera a regra de palavras-chave com margem cujo intervalo não inclui o zero e reconhece situações que a regra não alcança, como arquivamentos registrados antes da última movimentação. Essa conclusão vale para processos da justiça estadual de São Paulo e do Rio de Janeiro, com o mesmo tipo de texto da base.

Os resultados são adequados? São adequados para sugerir a situação com confirmação humana e inadequados para alterar o cadastro automaticamente. Mesmo com 92,2% de acurácia, o modelo classificou como arquivados 14 processos ativos no teste. No MVP, esse erro interromperia o acompanhamento de um processo em andamento, e por isso a sugestão nunca deve desligar a sincronização sozinha.

Quais variáveis foram mais relevantes? Os termos de encerramento (definitivamente, baixa, trânsito em julgado), os de arquivamento provisório e o vocabulário de remessa, recurso e tramitação para os ativos. A posição do termo importa, e a última movimentação concentra a maior parte do sinal. O tamanho do histórico, a origem e o ano não foram necessários, e os dois últimos introduziriam vieses.

Em que condições o modelo pode ser utilizado? Como sugestão, em textos de movimentação no formato dos tribunais estaduais representados na base, com limiar de confiança de pelo menos 0,8 e sem efeito automático sobre a sincronização. Para processos do TRT da 16ª Região, o uso depende de validação com uma amostra rotulada do próprio MVP, conforme a seção 9.3.

9.2 Limitações

Desbalanceamento. Com 98 suspensos no teste, as métricas dessa classe têm intervalo largo, e 25 suspensos ficaram sem reconhecimento. Os pesos balanceados reduziram, mas não eliminaram, a diferença para as outras classes.

Valores extremos. Históricos muito longos não afetam o modelo, que lê só as cinco últimas movimentações. Históricos muito curtos são raros (14 processos na base) e não permitem medir o desempenho nesse recorte.

Representatividade. A base cobre dois tribunais estaduais, não informa como os processos foram escolhidos nem quando foram rotulados, e o Rio de Janeiro não tem nenhum suspenso. Não há como saber se a proporção entre as classes reflete a de uma carteira real de escritório.

Sobreajuste e generalização. A diferença entre treino (0,999) e validação (0,901) mostra memorização. A queda nos testes temporais e o colapso do treino com o Rio aplicado a São Paulo mostram que o desempenho depende de o vocabulário do uso ser o mesmo do treino.

Método de avaliação. A divisão principal foi aleatória e agrupada, e não temporal, por falta de datas. Por isso o resultado do teste aleatório deve ser lido como teto, e os testes temporais como estimativa mais próxima do uso. O conjunto de teste foi avaliado mais de uma vez durante o trabalho, porque as revisões do mascaramento de nomes exigiram refazer a limpeza e o treino. Essas revisões foram motivadas pela proteção de dados pessoais, e não pelas métricas de teste, mas o registro fica feito.

Mascaramento. O léxico de nomes é heurístico. Nomes que nunca aparecem perto de uma OAB, de um papel processual ou de outro nome conhecido podem permanecer no texto tratado.

9.3 Relação com o MVP e próximos passos

O resultado valida a hipótese de que a situação de um processo pode ser inferida do texto das suas movimentações com qualidade suficiente para uma sugestão, e mostra que essa capacidade depende do vocabulário do tribunal. Para o MVP, o próximo passo é montar uma amostra rotulada de processos acompanhados pelo sistema, convertendo os movimentos do DataJud em texto da mesma forma usada na verificação da seção 8.10, e medir nela o desempenho do modelo atual. Se a queda for semelhante à do treino com o Rio aplicado a São Paulo, o modelo precisa ser retreinado com esses dados.

Com essa medição, a integração pode seguir o desenho da seção 3.2: a sincronização calcula a sugestão para cada processo com andamento novo, registra a probabilidade e mostra ao advogado as divergências entre a situação sugerida e a cadastrada, com o texto das movimentações que levaram à sugestão. O mesmo princípio de abstenção adotado na jurimetria vale aqui: abaixo do limiar, o sistema informa que não há sugestão.

10 REGISTRO DE DECISÕES E MUDANÇAS DE ABORDAGEM

A Tabela 12 reúne as decisões que alteraram o planejamento ou que se afastam de regras adotadas pelo projeto, com a etapa em que foram tomadas e o motivo.

Tabela 12 - Decisões e mudanças de abordagem

Código	Decisão	Etapa	Motivo
D1	Substituir o conjunto próprio pela base Brazilian Legal Proceedings	TED 01	413 casos treináveis, rótulos sem conferência humana e cobertura de 45% do assunto CNJ
D2	Trocar o problema de aprendizado: de deferimento por vara para situação do processo	TED 01	A base não tem pedido, resultado nem vara; as classes coincidem com o cadastro do MVP
D3	Manter dados brutos e textos tratados fora do repositório	TED 01 e 02	Licença declarada como "Unknown", 658 MB de arquivos e presença de nomes de pessoas
D4	Truncar movimentações em 2.000 caracteres	TED 02	Limite perto do percentil 99; o tipo do ato está no início
D5	Mascarar nomes com léxico construído dos próprios textos, revisado em três rodadas	TED 02 e 03	Nomes de advogados apareceram entre os termos de maior peso do modelo; a primeira versão do léxico apagava termos institucionais
D6	Divisão aleatória agrupada no lugar da temporal	TED 03	Ausência de data por movimentação; recortes temporais mantidos como verificação. Desvio da regra de avaliação do projeto
D7	Janela de cinco movimentações, com a última em bloco separado	TED 03	Melhor janela no E1; a separação foi mantida por interpretabilidade, com ganho dentro da variação entre dobras (E4)
D8	Regressão logística em vez da SVM linear	TED 03	Empate dentro do desvio entre dobras; necessidade de probabilidades
D9	Não usar o número de movimentações nem o vocabulário da base sem rótulo	TED 03	Ganho abaixo da variação entre dobras
D10	Não integrar o modelo ao back-end nesta entrega	TED 03	Ramo de justiça diferente do MVP; falta medir o desempenho em processos do TRT-16

Fonte: elaborado pela equipe (2026).

11 REPOSITÓRIO, DADOS E REPRODUÇÃO

O código e os resultados estão no repositório https://github.com/eChavez404/Juripredict. A Tabela 13 lista os arquivos desta etapa.

Tabela 13 - Arquivos das TEDs de dados no repositório

Arquivo	Conteúdo
src/ted01_baixar_e_inspecionar.py	Download da base, conferência do SHA-256 e inspeção da estrutura
src/ted02_limpar_e_explorar.py	Limpeza, mascaramento, base tratada, estatísticas e gráficos da análise exploratória
src/ted03_modelar.py	Linhas de base, experimentos, teste, abstenção, generalização e modelo final
src/test_limpeza.py	Testes automatizados das regras de limpeza
src/requirements.txt	Dependências com versões fixas
resultados/ted01_inspecao.json	Contagens, tamanhos e SHA-256 da base original
resultados/ted02_resumo.json	Problemas de qualidade, estatísticas descritivas e testes da análise exploratória
resultados/ted02_base_tratada_metadados.csv	Base tratada sem o texto das movimentações
resultados/ted03_resultados.json	Métricas de todos os experimentos, do teste e da generalização
resultados/ted03_particao.csv	Processos do desenvolvimento e do teste
resultados/figuras/	Figuras deste documento

Fonte: elaborado pela equipe (2026).

Os dados não estão no repositório, pelos motivos da decisão D3. O script da TED 01 baixa os dois arquivos diretamente do Kaggle, sem credencial, pelo endereço https://www.kaggle.com/api/v1/datasets/download/felipepolo/brazilian-legal-proceedings/ seguido do nome do arquivo, e interrompe a execução se o resumo SHA-256 não corresponder à versão 2 usada neste documento:

labeled.json: 653013a741af31ad389f44458bc0bf5fd4c78a380646556d0772dee47846c63a

unlabeled.json: 0451bc19da272cd849a25e510d44ad1735f42a51436514eff114bba7fece3042

Os arquivos baixados e os tratados ficam na pasta *data/*, ignorada pelo Git; outra pasta pode ser indicada pela variável de ambiente DADOS_DIR. A execução exige Python 3.12 e as bibliotecas de *src/requirements.txt*: numpy 2.5.4, pandas 3.1.0, scipy 1.18.1, scikit-learn 1.9.1, matplotlib 3.11.2, joblib 1.6.0 e pytest 9.2.0. A partir da raiz do repositório, a sequência é:

```
python -m venv .venv-dados
pip install -r src/requirements.txt
python src/ted01_baixar_e_inspecionar.py
python src/ted02_limpar_e_explorar.py
python src/ted03_modelar.py
python -m pytest src/test_limpeza.py
```

Em um notebook com 8 GB de memória, a limpeza levou cerca de seis minutos e a modelagem cerca de sete minutos. A semente fixa (42) torna a divisão dos dados e os resultados reproduzíveis. O modelo treinado é gravado em *data/processed/modelo_status.joblib* e, como os dados, não é versionado. No Windows, o ambiente virtual precisa ficar em um caminho curto, porque a importação do scikit-learn falha quando o caminho completo de algum arquivo passa de 260 caracteres.

REFERÊNCIAS

BRASIL. Lei nº 13.105, de 16 de março de 2015. Código de Processo Civil. Brasília: Presidência da República, 2015.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais. Brasília: Presidência da República, 2018.

LAGE-FREITAS, André; ALLENDE-CID, Héctor; SANTANA, Orivaldo; OLIVEIRA-LAGE, Lívia. Predicting Brazilian court decisions. *PeerJ Computer Science*, v. 8, e904, 2022. DOI: 10.7717/peerj-cs.904.

LUZ DE ARAUJO, Pedro Henrique; DE CAMPOS, Teófilo Emídio; BRAZ, Fabricio Ataides; DA SILVA, Nilton Correia. VICTOR: a dataset for Brazilian legal documents classification. In: LANGUAGE RESOURCES AND EVALUATION CONFERENCE, 12., 2020, Marseille. *Proceedings* [...]. Paris: European Language Resources Association, 2020. Disponível em: https://aclanthology.org/2020.lrec-1.181. Acesso em: 1 nov. 2026.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

POLO, Felipe Maia. *Brazilian Legal Proceedings*. Versão 2. Kaggle, 2021. Disponível em: https://www.kaggle.com/datasets/felipepolo/brazilian-legal-proceedings. Acesso em: 1 nov. 2026.

POLO, Felipe Maia; CIOCHETTI, Itamar; BERTOLO, Emerson. Predicting legal proceedings status: approaches based on sequential text data. In: INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE AND LAW, 2021. *Proceedings* [...]. New York: Association for Computing Machinery, 2021. p. 264-265. DOI: 10.1145/3462757.3466138. Versão estendida disponível em: https://arxiv.org/abs/2003.11561. Acesso em: 1 nov. 2026.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Declaro/Declaramos, para os devidos fins, que o conteúdo apresentado nesta atividade é de minha/nossa responsabilidade, incluindo sua autoria, análise, validação e veracidade.

Durante a elaboração desta atividade:

( ) Não foram utilizadas ferramentas de Inteligência Artificial.

(X) Foram utilizadas ferramentas de Inteligência Artificial, conforme descrito abaixo.

1. Ferramentas utilizadas

Claude (Anthropic), por meio do Claude Code.

2. Forma de utilização

A partir da decisão da equipe de substituir a base de dados pela Brazilian Legal Proceedings, a ferramenta escreveu e redigiu a versão preliminar deste documento com base nos resultados gravados pelos scripts.

3. Evidências de utilização

O histórico da sessão com a ferramenta e o versionamento do repositório do projeto podem ser apresentados ao professor quando solicitados.

Declaro/Declaramos que as informações acima são verdadeiras e que compreendo/compreendemos que o uso de Inteligência Artificial não transfere à ferramenta a responsabilidade pela atividade desenvolvida.

Responsável(is) pela atividade:

Nome(s): Elias Chaves Sousa, Kauan Leite, Marcos Cirqueira, Pedro Vitor Rocha

Assinatura(s): _____

Data: ___ / ___ / _____